

# 電力需要ポートフォリオ最適化問題に対する パウリ相関エンコーディングを用いた 量子最適化手法の実装と評価

吉岡 匠哉<sup>1,a)</sup> 笹田 啓太<sup>1</sup> 中野 裕一郎<sup>2</sup> 藤井 啓祐<sup>2,3,4</sup>

**概要:** 本稿では、電力需要ポートフォリオ最適化問題に対して、パウリ相関エンコーディング (PCE: Pauli Correlation Encoding) を用いた量子最適化手法の実装と評価を行う。PCE は、高次元の古典的決定変数を、少数の量子ビット上で作用する相関した Pauli 演算子の期待値として表現する量子符号化手法であり、物理量子ビット数を抑えたまま、多数の相関変数を同時に扱うことを可能にする。本研究では、実数係数を持つ密結合二次最適化問題として電力需要ポートフォリオ最適化問題を定式化し、PCE に基づく変分量子回路を設計・実装した。状態ベクトルシミュレーションにより、問題サイズ  $m = 20, 60$  および  $m = 210$  のインスタンスに対して数値実験を行い、固定深さの変分回路における最適化の収束挙動および解の精度を評価した。その結果、PCE を用いることで少数の量子ビットによる効率的な問題表現が可能であり、密な二次構造を持つ電力需要ポートフォリオ最適化問題に対しても安定した最適化性能が得られることを確認した。本稿は、PCE に基づく量子最適化手法の実装上の要点と、中規模問題における基礎的性能評価を示すものである。

## Implementation and Evaluation of a Quantum Optimization Method Using Pauli Correlation Encoding for the Power Demand Portfolio Optimization Problem

### 1. はじめに

電力システムの運用は、分散型エネルギー資源の普及、再生可能エネルギーの大量導入、および需要・市場価格の不確実性の増大に伴い、ますます高度な最適化技術への依存を強めている [1], [2], [3]。とりわけ、アグリゲータによる電力需要ポートフォリオ最適化は、需要家の部分集合を選択することで調達目標を達成しつつ、需要変動やリスクを抑制する問題として定式化され、本質的に大規模かつ高次元の組合せ最適化問題へと帰着する [4], [5]。この種の問題は、需要プロファイル間の相関を反映した密な二次相互作用を含むことが多く、実数値係数を持つ完全結合型 QUBO 問題として特徴付けられる。

このような高次元かつ密結合な最適化問題に対し、従来の厳密解法は指数的計算コストの制約を受けるため、代替的計算枠組みの探索が進められている。その有力な候補の一つが、近年の量子デバイスに適した柔軟な計算パラダイムとして注目される変分量子アルゴリズム (Variational Quantum Algorithms; VQA) である。VQA は組合せ最適化問題への応用が活発に研究されているが、実用規模問題への適用に際してはスケーラビリティ上の根本的課題を抱えている。すなわち、現行ハードウェアで利用可能な量子ビット数は依然として限定的である一方、実際の意思決定問題は非常に高次元の古典変数空間を必要とする。限られた量子資源と高次元古典表現とのギャップをどのように橋渡しするかは、量子最適化における中心的課題である。

代表的な手法である量子近似最適化アルゴリズム (Quantum Approximate Optimization Algorithm; QAOA) では [6], [7]、二値決定変数を量子ビットへ直接対応付ける定式化が一般的である。この一対一対応は概念的には単純で

<sup>1</sup> TIS 株式会社 戦略技術センター  
<sup>2</sup> 大阪大学 大学院基礎工学研究科  
<sup>3</sup> 大阪大学 量子情報・量子生命研究センター  
<sup>4</sup> 理化学研究所 量子コンピュータ研究センター  
<sup>a)</sup> yoshioka.takuya@tis.co.jp

あるが、変数数に比例して必要な量子ビット数が増加するため、高次元問題への適用は困難である。さらに、電力需要ポートフォリオのような密な二次相互作用を持つ問題では、多数の結合項の実装が必要となり、回路深さや結合構造の観点からも制約が厳しい。これらの背景から、問題次元と量子ビット数を切り離す新たな符号化戦略が求められている。

そのような代替的表現手法として、Sciorilli らにより提案されたパウリ相関エンコーディング (Pauli Correlation Encoding; PCE) がある [8]。PCE では、古典的二値変数を個々の量子ビットに割り当てる代わりに、変分量子回路によって生成される相関した Pauli 演算子の期待値の符号として表現する。相関次数を  $k$  に固定した場合、利用可能な Pauli 相関子の数は

$$m = 3 \binom{n}{k}$$

と組合せ的に増加し、比較的少数の量子ビットによって多数の古典変数を表現できる。

PCE はこれまでに、ポートフォリオ最適化問題、構造化組合せ最適化ベンチマーク、およびウォームスタート戦略との組合せなど、いくつかの設定で検討されてきた [9], [10], [11]。これらの研究は、PCE が量子ビット効率の高い表現を提供し得ることを示唆している一方、検証は主として中規模あるいは構造化問題に限定されている。

現実の電力最適化問題では、完全結合型の二次相互作用、実数値係数、および非一様な統計構造が自然に現れる。このような密で非構造的な条件下における PCE の性能評価は、その実用的有効性を判断する上で不可欠である。

本技術報告書では、電力需要ポートフォリオ最適化問題を対象として、PCE に基づく量子最適化手法の実装と評価を行う。計算モデルとして  $m = 20, 60, 210$  の問題を取り上げ、中規模設定における最適化挙動および実装特性を検討する。

## 2. 電力需要ポートフォリオ最適化問題

電力需要ポートフォリオ最適化問題は、電力アグリゲータの運用において発生する重要な意思決定問題であり、需要家の部分集合を選択することで、調達目標を満たしつつ、需要の不確実性や変動性を管理することを目的とする [1], [2], [3]。

### 2.1 問題設定

本研究では、不確実性下で所定量の電力を調達するために、電力アグリゲータが需要側リソースの部分集合を選択する電力需要ポートフォリオ最適化問題を考える [4], [12]。需要家  $i$  の時刻  $t$  における電力消費量を  $p_{t,i}$  とし、需要の確率的変動を反映する確率変数として扱う。アグリゲータは、ポートフォリオに含まれる需要家の総需要が、あらか

じめ与えられた調達目標  $P_t^{\text{target}}$  にできるだけ一致するようにしつつ、需要の不確実性に起因する変動を抑制することを目的とする。

ポートフォリオの選択は、二値決定変数  $\mathbf{x} = (x_1, \dots, x_m) \in \{0, 1\}^m$  によって表され、 $x_i = 1$  は需要家  $i$  をポートフォリオに含めることを意味する。この定式化は、二次のコスト構造を持つ高次元の組合せ最適化問題を自然に導き、大規模な設定では古典的な厳密解法にとって困難な問題となる。

### 2.2 パウリ相関エンコーディング

パウリ相関エンコーディング (Pauli Correlation Encoding; PCE) は、多数の決定変数を相関した Pauli 演算子の期待値として埋め込むことで、大規模な組合せ最適化問題を効率的に表現する手法である。PCE では量子ビット数  $n$  に対して有効な問題次元  $m$  が組合せ的に増大するため、比較的少数の量子ビットを用いて、現実的な規模の電力需要ポートフォリオ問題を扱うことが可能となる。

#### 2.2.1 本研究で用いる変分量子回路

本研究では、量子回路を単独の量子アルゴリズムとしてではなく、Pauli 相関子を生成する学習型のパラメータ付き量子回路として用いる。回路の深さは全ての計算において 5 に固定する。ここで 1 層は、(i) 全量子ビットに対する  $R_y$  回転、(ii) 全量子ビットに対する  $R_z$  回転、(iii) 全結合型の  $ZZ$  相互作用の逐次適用から構成される。

回路深さを  $l$  とした場合、各層には  $\binom{n}{2}$  個の二量子ビット  $ZZ$  相互作用と、 $O(n)$  個の単一量子ビット回転が含まれ、全体として  $O(ln^2)$  個のエンタングリングゲートを要する。本実装では、各層あたり  $\binom{n}{2} + 2n$  個の基本ゲートに相当する。なお、回路深さを増加させた予備的検証においても、収束挙動に本質的な変化は見られず、最適化性能を支配する主要因は回路深さよりも Pauli 相関子による表現空間の大きさであることが示唆された。

#### 2.2.2 コストモデル：時間平均型と時間分解型

本研究では、電力需要ポートフォリオ最適化問題に対して、時間分解型の異なる 2 つの関連したコストモデルを導入する。両モデルはいずれも同一の時間別コスト関数に基づいているが、需要変動の扱い方が異なる。以下では、ポートフォリオの次元、すなわち資産数を  $m$  とする。

##### 2.2.2.1 時間別コスト関数

時刻  $t$  におけるポートフォリオ構成  $\mathbf{x}$  に対する時間別コストを

**表 1** 時間平均モデル (Model 1) における問題サイズ  $m$  と最適化設定およびコストの収束結果のまとめ. コスト値として,  $\Delta C_T/W_T = (C_T - C_T^{\min})/(C_T^{\max} - C_T^{\min})$  の計算結果を表す.

$m$	$n$	$k$	$\alpha_{sc}$	$\beta$	$\nu$	$n_{\text{params}}$	$n_{\text{iter}}$	$\Delta C_T/W_T(\text{PCE})$	$\Delta C_T/W_T(\text{Greedy})$
20	5	2	1.5	0.1	1765.31	100	316	$1.89 \times 10^{-4}$	$1.82 \times 10^{-3}$
60	6	3	0.1	0.1	615.30	135	458	$6.47 \times 10^{-4}$	$4.67 \times 10^{-3}$
210	8	4	0.1	0.1	271.63	220	1291	$5.44 \times 10^{-4}$	$2.36 \times 10^{-3}$

$$C_t(\mathbf{x}) = \frac{1}{m^2} \mathbb{E} \left[ \left( \sum_{i=1}^m p_{t,i} x_i - P_t^{\text{target}} \right)^2 \right] \\ = \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m \text{Cov}(p_{t,i}, p_{t,j}) x_i x_j \\ + \frac{1}{m^2} \left( \sum_{i=1}^m \mathbb{E}[p_{t,i}] x_i - P_t^{\text{target}} \right)^2 \quad (1)$$

と定義する. ここで  $m^2$  による正規化は, ポートフォリオサイズの増大に伴う目的関数値および勾配の過度な増加を抑え, 変分最適化の数値安定性を向上させるために導入している. この量は, 各時刻における調達電力量と目標値との差を, 需要の確率変動と平均値の双方を考慮した形で評価するものである.

#### 2.2.2.2 データセットと問題生成

次に, 本研究で用いるデータセットおよび異なる規模の問題インスタンスの生成方法について述べる. モデルパラメータは, Energy Management System Open Data プラットフォームで公開されている電力消費データに基づいて構成した [13]. データセットは, 4月1日から5月30日までの61日間にわたる1時間毎の電力消費記録からなり, 2,143 個の独立な需要家時系列を含む.

各需要家  $i$  および時刻  $t$  に対して, 利用可能な需要削減量  $p_{t,i}$  を元の電力消費量の 10% として定義する. また, 時刻  $t$  における調達目標電力量は, 全需要削減量の半分として

$$P_t^{\text{target}} = \frac{1}{2} \sum_{i=1}^m p_{t,i}$$

と設定する. 本稿では, 利用可能な需要家集合から異なる  $m$  人を選挙してポートフォリオを構成する.

#### 2.2.2.3 モデル 1: 時間平均型ポートフォリオ最適化

モデル 1 は, 長さ  $n_T$  の対象とする時間帯にわたって共通のポートフォリオを選択する時間平均型の定式化である. このモデルは, 需要不確実性の支配的な統計構造を捉えることを目的として導入され, 量子最適化における有効な初期回路パラメータを得るために用いられる.

時間平均コスト関数は

$$C_T(\mathbf{x}) = \frac{1}{n_T} \sum_{t=T}^{T+n_T} C_t(\mathbf{x}) \quad (2)$$

と定義される.  $C_t(\mathbf{x})$  の定義を代入することで,

$$C_T(\mathbf{x}) = \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m \overline{\text{Cov}(p_{t,i}, p_{t,j})} x_i x_j \\ + \frac{1}{n_T} \sum_{t=T}^{T+n_T} \frac{1}{m^2} \left( \sum_{i=1}^m \mathbb{E}[p_{t,i}] x_i - P_t^{\text{target}} \right)^2 \quad (3)$$

と書き換えられる. ここで上線は時間間隔  $n_T$  にわたる平均を表す. 本研究では基準時刻を  $T = 1$  とし, 平均化窓は  $n_T = 24$  に固定する. この平均化モデルは, 粗視化された最適化ランドスケープを与え, 初期パラメータ決定に特に適している.

#### 2.2.2.4 モデル 2: 時間分解型ポートフォリオ最適化

モデル 2 は, 時間ごとのコストを積算して最小化する完全な時間分解型の定式化であり, 実運用における需要変動下での調達性能評価を表すモデルである.

後の解析のために, 各時刻  $t$  における期待調達電力量およびその変動幅を定義する. 期待調達電力量は

$$P_t(\mathbf{x}) = \sum_{i=1}^m \mathbb{E}[p_{t,i}] x_i \quad (4)$$

で与えられ, 対応する標準偏差は

$$\sigma_t(\mathbf{x}) = \sqrt{\sum_{i=1}^m \sum_{j=1}^m \text{Cov}(p_{t,i}, p_{t,j}) x_i x_j} \quad (5)$$

と定義される. これらは調達電力量の平均および変動性を特徴付ける量であり, Sec. 3 におけるポートフォリオの頑健性評価に用いられる. これらを用いると, Eq. (1) の時間別コストは

$$C_t(\mathbf{x}) = \frac{1}{m^2} \sigma_t(\mathbf{x})^2 + \frac{1}{m^2} [P_t(\mathbf{x}) - P_t^{\text{target}}]^2 \quad (6)$$

と直感的に表現できる.

最適化結果の正規化および比較のために, 基準となる最小・最大コスト値を定義する. 最小コスト  $C_t^{\min}$  および  $C_t^{\max}$  は, 相対最適性ギャップ  $10^{-4}$  を許容した Gurobi オプティマイザ [14] によって求める. 対応する最大値  $C_t^{\max}$  および  $C_t^{\min}$  は, 同一の問題インスタンス内で一貫した方法により定義する. これらの値は, 本研究全体を通じて正規化コストおよび損失指標を定義するための参照値として用いる.

### 2.2.3 連続緩和と損失関数

変分量子最適化を可能にするため、本研究では二値変数  $x$  を、量子回路のパラメータ  $\theta$  によって定まる連続変数  $y(\theta) \in [0, 1]^m$  へと緩和する。変分パラメータ  $\theta$  は、量子回路をシミュレーションし、必要な Pauli 演算子の期待値を評価することで得られる損失関数を最小化するように最適化される。本研究におけるすべての変分最適化は、Qulacs シミュレータ [15] を用いたノイズレスな状態ベクトルシミュレーションにより実行した。得られる損失関数は滑らかな形状を持つため、勾配に基づく古典最適化手法を適用することが可能である。本研究では、検討したすべての問題サイズにおいて安定かつ効率的な収束が確認された Broyden–Fletcher–Goldfarb–Shanno (BFGS) 法を用いて最適化を行った。損失関数の勾配は期待値から厳密に計算され、数値効率向上のため、状態ベクトルシミュレータに実装されたバックプロパゲーション機能を用いて評価した [15]。

PCE の枠組みにおいて、緩和変数は  $k$  体の Pauli 相関演算子  $\Pi_i^{(k)}$  の期待値を用いて

$$y_i(\theta) = \varsigma(2\alpha\langle\psi(\theta)|\Pi_i^{(k)}|\psi(\theta)\rangle) \quad (7)$$

と定義される。ここで  $\varsigma(x) = [1 + e^{-x}]^{-1} = [\tanh(x/2) + 1]/2$  はシグモイド関数であり、 $\alpha$  は緩和の鋭さを制御するパラメータである。

これらの緩和変数を用いて、時間分解型モデルに対する損失関数を

$$L_t(\theta) = C_t(y(\theta)) + \frac{\beta\nu}{m} \sum_{i=1}^m \left[ y_i(\theta) - \frac{1}{2} \right]^2 \quad (8)$$

と定義する。ここで  $\beta$  は正則化の強さを制御する調整パラメータであり、 $\nu = \|Q\|_F$  は QUBO 行列のフロベニウスノルムを表す。時間平均型モデルに対しても、同様に  $C_t$  を  $C_T$  に置き換えることで損失関数を定義する。 $\nu$  の評価においては、 $(P_t^{\text{target}})^2$  のように決定変数に依存しない定数項は除外している。

### 2.2.4 デコーディングおよびウォームスタート戦略

実際の計算では、時間平均型モデル（モデル 1）で最適化された回路パラメータを、時間分解型モデル（モデル 2）の初期値として用いるウォームスタート戦略を採用する。この方法により、実運用を想定した定式化においても、収束性および最適化の安定性が大きく向上することを確認した。

最適化終了後、Pauli 相関演算子の期待値を用いて、二値のポートフォリオ選択を以下のようにデコードする：

$$x_i := \frac{1}{2} \left\{ \text{sign} \left[ \langle\psi(\theta)|\Pi_i^{(k)}|\psi(\theta)\rangle \right] + 1 \right\}. \quad (9)$$

得られた二値解は、元のコスト関数を用いて再評価され、調達精度および安定性の観点から性能評価を行う。

さらに、量子回路の変分パラメータが完全に最適化され、最適化過程が終了した後、最適化軌道全体の中で最小のコスト値を与えた解に対して事後処理を適用する。この事後処理として、Sciorilli らが採用した局所探索法 [8] と貪欲法の双方を検証した結果、貪欲法の方が一貫して良好な性能を示すことが確認された。そのため、本研究では貪欲法を事後処理手法として採用する。

## 3. 数値結果

本節では、電力需要ポートフォリオ最適化問題に対するパウリ相関エンコーディング (PCE) を用いた量子最適化手法の数値的性能を評価する。計算モデルのサイズとして  $m = 20, 60, 210$  の 3 種類を取り上げ、時間平均型モデル (Model 1) および時間分解型モデル (Model 2) の双方について検証を行う。

まず、階層的最適化枠組みの初期段階として時間平均型最適化問題 (Model 1) を評価する。Model 1 を解くことで、コストランドスケープの支配的構造を反映した変分回路パラメータが得られ、これを時間分解型最適化 (Model 2) の初期値として利用する。

### 3.1 PCE に基づく最適化のスケラビリティ (Model 1)

表 1 に、最適化設定および収束統計をまとめる。また、Model 1 における問題サイズ  $m$  と正規化コストの関係を示す。

$m = 20, 60, 210$  のいずれの問題サイズにおいても、PCE に基づくソルバは低い正規化コストを安定して達成しており、体表的なヒューリスティクスの貪欲法と比較して、少数の量子ビットによる効率的な最適化が確認できる。

### 3.2 時間分解型最適化とウォームスタート効果 (Model 2)

次に、時間分解型モデル (Model 2) に対する最適化挙動を評価する。Fig. 1 に、 $m = 210$  の場合の収束過程を示す。

ランダム初期化に比べ、時間平均型モデルで得られたパラメータを用いたウォームスタート初期化は、収束速度の向上および最終到達コストの低減に寄与することが確認された。この結果は、階層的最適化戦略が、実運用を想定した時間分解型問題に対して有効であることを示している。

以上の結果より、PCE を用いた量子最適化手法は、 $m = 20, 60, 210$  の範囲において安定した最適化性能を示し、電力需要ポートフォリオ最適化問題に対する有効な量子表現および最適化フレームワークとなり得ることが確認された。

次に、時間分解型最適化 (Model 2) の性能について、需要一致精度および最適化解の不確実性の観点から評価する。

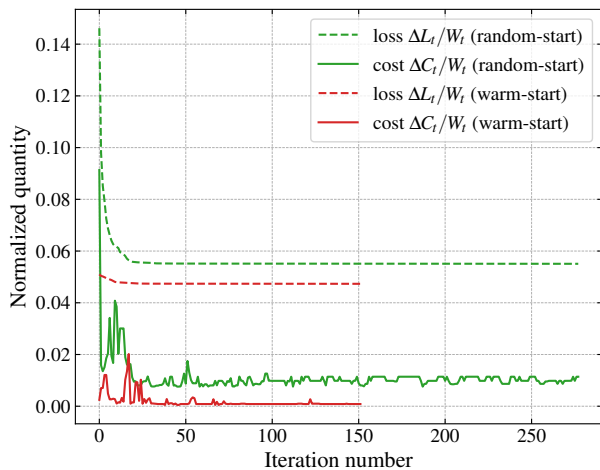


図 1 時間分解型最適化 (Model 2) における問題サイズ  $m = 20$ , 時刻  $t = 15$  の収束挙動. 横軸は最適化の反復回数, 縦軸は正規化された量を示しており, 損失関数およびコスト関数に対応する  $\Delta L_t/W_t = (L_t - C_t^{\min})/(C_t^{\max} - C_t^{\min})$ ,  $\Delta C_t/W_t = (C_t - C_t^{\min})/(C_t^{\max} - C_t^{\min})$  をそれぞれ表す. ランダム初期化は変分回路パラメータを無作為に設定した場合を示し, ウォームスタートは時間平均型モデル (Model 1) で最適化されたパラメータを初期値として用いた場合を示す. ウォームスタート初期化により, 収束が高速化し, 最終到達コストが低減されることが分かる. ランダム初期化は比較のため  $n_{\text{runs}} = 1$  の代表例を示している. 基準値  $C_t^{\min}$  および  $C_t^{\max}$  は, 相対最適性ギャップ  $10^{-4}$  を許容した商用ソルバ Gurobi [14] により求めた. 本図の結果はいずれも事後処理を適用していない.

まず, ウォームスタート初期化が収束挙動に与える影響を検討する. Fig. 1 に, ウォームスタート初期化とランダム初期化により得られた最適化軌跡の比較を示す. Model 1 で得られた解を用いて変分パラメータを初期化することで, ランダム初期化に比べて一貫して収束が高速化し, かつ最終到達コストも低減されることが確認された. また,  $t = 11$  から  $t = 20$  のすべての時間ステップにおいて, 同様の収束傾向が観測されており, ウォームスタートの優位性が対象とする時間帯にわたり頑健であることが示唆される.

### 3.3 時間分解精度とポートフォリオ安定性の評価

Fig. 2 は,  $m = 210$  の電力需要ポートフォリオ最適化問題における実際の調達プロファイルを示したものである. 時間分解型モデルに基づき, 複数の需要家から提供される需要側柔軟性が, 各時刻においてどのように集約され, 目標電力量を満たす調達が行われているかを時間発展に沿って可視化している.

積み上げ面グラフは, 選択された需要家ごとの調達電力量を色分けして表しており, 積み上げ上端が期待調達電力量  $P_t$  に対応する. また, 目標電力量  $P_t^{\text{target}}$  は破線で示され, 網掛け領域は調達電力量の不確実性幅  $\pm \sigma_t$  を表す.  $m = 210$  の設定では, 個々の需要家の寄与の合計は目標電

力量を満たす調達に良く合致していることが確認できる. また, 時間全体にわたって不確実性幅が比較的抑制されており, 安定した調達挙動が実現されていることが分かる.

本技術報告書では, 計算規模および紙面の制約を考慮し,  $m = 210$  の代表的な結果のみを掲載したが, 本図は, パウリ相関エンコーディング (PCE) に基づく量子最適化手法が, 中規模の時間分解型電力需要ポートフォリオ問題に対しても, 実用的な調達精度と安定性を両立できることを示している.

貪欲法および商用ソルバによる参照解と比較しても, PCE 法は需要不一致および不確実性を一貫して低く抑える結果を示した. 以上より, 提案する量子最適化フレームワークは, 時間分解型の運用状況においても高精度かつ安定した調達挙動を実現できること, さらに従来の MIP ソルバが収束困難となる規模に対しても頑健に適用可能であることが確認された.

## 4. まとめ

本稿では, パウリ相関エンコーディング (Pauli Correlation Encoding; PCE) に基づく変分量子最適化手法を用いて, 電力需要ポートフォリオ最適化問題に対する実装と評価を行った. 高次元の決定変数を相関した量子演算子へと圧縮することで, 量子ビット数に対して有効な問題サイズが組合せ的に増大することを示した.

数値実験では, 計算モデルのサイズとして  $m = 20, 60, 210$  の 3 種類を取り上げ, 時間平均モデル (Model 1) において貪欲法との比較評価を行った. その結果, PCE に基づく最適化手法は, いずれの問題サイズにおいても, 正規化コストで評価した誤差が貪欲法に比べて一桁以上小さいことが確認された. また, 需要の不確実性を考慮した条件下においても, 最適化過程は安定した収束挙動を示した.

特に  $m = 210$  のケースでは, 時間分解型モデルに基づく実際の調達電力プロファイルを積み上げグラフとして可視化し, 得られたポートフォリオが目標電力量に対して安定的に追従している様子を確認した. この結果は, PCE に基づく最適化によって得られた解が, 単にコスト関数の値を低減するだけでなく, 時間的に整合性の取れた電力調達を表現している.

本研究は, 量子最適化手法と, エネルギーシステム分野における実問題との間に具体的な接点を与えるものであり, 量子情報科学と電力工学の融合領域における今後の研究に向けた基盤を提供する. 本稿では電力需要ポートフォリオ最適化問題を対象としたが, 提案した枠組みはエネルギーシステムに限らず, 実数値係数を持つ一般の密な二次最適化問題にも直接適用可能である.

## 謝辞

本研究の一部は, 文部科学省「量子・AI 融合技術」




図 2  $m = 210$  の電力需要ポートフォリオ最適化問題における調達プロファイル。(a) 貪欲法, (b) パウリ相関エンコーディング (PCE) 法, (c) 最適解の結果をそれぞれ示す。各パネルにおいて、目標電力量  $P_t^{\text{target}}$  を黒の破線で、期待調達電力量  $P_t$  を実線で示す。また、網掛け領域は不確実性幅  $\pm\sigma_t$  を表す。積み上げ面グラフは選択された需要家ごとの調達電力量を色分けして可視化したものであり、積み上げ上端が  $P_t$  に対応する。結果は、各時刻を独立に最適化した  $t = 11$  から  $t = 20$  までの 1 時間刻みの値を示している。最適解は商用数値最適化ソルバ Gurobi (version 12.0.3) [14] を用い、MIP 相対ギャップ  $10^{-4}$  の設定で求めた。

ジネス開発グローバル拠点」(Q-LEAP) (課題番号: JP-MXS0118067394, JPMXS0120319794) の支援を受けて実施された。また、本研究は、科学技術振興機構 (JST) 共創の場形成支援プログラム (COI-NEXT) (課題番号: JP-MJPF2014) の支援を受けている。

## 参考文献

- [1] M.H. Albadi and E.F. El-Saadany. A summary of demand response in electricity markets. *Electric Power Systems Research*, 78(11):1989–1996, 2008.
- [2] Pierluigi Siano. Demand response and smart grids—a survey. *Renewable and Sustainable Energy Reviews*, 30:461–478, 2014.
- [3] Peter Palensky and Dietmar Dietrich. Demand side management: Demand response, intelligent energy systems, and smart loads. *IEEE Transactions on Industrial Informatics*, 7(3):381–388, 2011.
- [4] Tsuyoya Tsurumi and Kenichi Syoji. A design method for electric power demand portfolio and its basic investigation – proposition of a method for a resource aggregator to procure negawatt effectively –. (C18005), 2019. CRIEPI Technical Report.
- [5] Ricardo Faia, Tiago Pinto, Zita Vale, and Juan Manuel Corchado. Portfolio optimization of electricity markets participation using forecasting error in risk formulation. *International Journal of Electrical Power and Energy Systems*, 129:106739, 2021.
- [6] Edward Farhi, Jeffrey Goldstone, and Sam Gutmann. A quantum approximate optimization algorithm. 2014.
- [7] Stuart Hadfield, Zhihui Wang, Bryan O’Gorman, Eleanor G. Rieffel, Davide Venturelli, and Rupak Biswas. From the quantum approximate optimization algorithm to a quantum alternating operator ansatz. *Algorithms*, 12(2), 2019.
- [8] Marco Sciorilli, Lucas Borges, Taylor L. Patti, Diego García-Martín, Giancarlo Camilo, Anima Anandkumar, and Leandro Aolita. Towards large-scale quantum optimization solvers with few qubits. *Nature Communications*, 16:476, 2025.
- [9] V. P. Soloviev and M. Krompiec. Large-scale portfolio optimization using pauli correlation encoding. 2025.
- [10] M. Sciorilli, G. Camilo, T. O. Maciel, and A. Canabarro. A competitive nisq and qubit-efficient solver for the labs problem. 2025.
- [11] R. S. do Carmo, R. G. dos Reis, and S. F. F. Silva. Warm-starting pce for traveling salesman problem. *Brazilian Journal of Optimization*, 12:45–67, 2026.
- [12] Takuya Yoshioka, Keita Sasada, Yuichiro Nakano, and Keisuke Fujii. Electric power demand portfolio optimization by fermionic qaoa with self-consistent local field modulation. In *2024 IEEE International Conference on Quantum Computing and Engineering (QCE)*, volume 01, pages 469–475, 2024.
- [13] Sustainable open Invitation Initiative. Energy management system. <https://www.ems-opendata.jp>, 2026.
- [14] Gurobi Optimization, LLC. Gurobi optimizer reference manual. <https://www.gurobi.com>, 2026.
- [15] Yasunari Suzuki, Yoshiaki Kawase, Yuya Masumura, Yuria Hiraga, Masahiro Nakadai, Jiabao Chen, Ken M. Nakanishi, Kosuke Mitarai, Ryosuke Imai, Shiro Tamiya, Takahiro Yamamoto, Tennin Yan, Toru Kawakubo, Yuya O. Nakagawa, Yohei Ibe, Youyuan Zhang, Hirotsugu Yamashita, Hikaru Yoshimura, Akihiro Hayashi, and Keisuke Fujii. Qulacs: a fast and versatile quantum circuit simulator for research purpose. *Quantum*, 5:559, October 2021.